FIAP · Ciência da Computação · 1º ano · Global Solution 2026.2 · CitizenTech

Do registro à decisão

O que os registros oficiais de enchentes no Brasil (2013-2025) dizem para o Plantão Enchente

Relatório estatístico · Modelagem Linear para Aprendizado de Máquina

Integrante	RM
Gabriel Barbosa Furin	572941
Lucas Kiodi Moraca	571004
Renan Fracalossi Mano da Silva	569610

Novembro de 2026

Aviso. Trabalho acadêmico. Os modelos descrevem registros históricos e não substituem os alertas da Defesa Civil (telefone 199) nem do Cemaden. A análise usa dados públicos oficiais e nenhum dado pessoal.

1. Resumo executivo

Entre 2013 e 2025 o Brasil registrou **6 750 enchentes municipais** (alagamentos, enxurradas e inundações), com **373 mortes**, **2 983 595 pessoas afetadas** e cerca de **R$ 27.1 bilhões** em prejuízos (valores nominais). A análise abaixo transforma esses registros em respostas para três decisões do Plantão Enchente: onde concentrar o conteúdo do assistente, o que sinaliza mais enchentes e quando o risco de morte deve acionar mensagens de segurança mais fortes.

- **Onde.** O Sul concentra 42% dos registros (2 833); só Santa Catarina (1 324) e o Rio Grande do Sul (1 140) somam 37% do país.
- **O que acompanha as enchentes.** Estados e anos com mais registros de chuvas intensas têm mais registros de enchente ($r = 0.69$). Dobrar os registros de chuvas intensas está associado a cerca de 1.48 vezes mais registros de enchente. Com movimento de massa, vendavais e estiagem, o modelo múltiplo explica 58% da variação ($R^2 = 0.58$).
- **Quando o risco é letal.** Um modelo logístico acerta 84.6% dos estados-ano (84.3% em validação cruzada), contra 73.2% de quem sempre previsse "sem óbito". Baixar o corte de 0.50 para 0.30 eleva a sensibilidade de 67.0% para 86.2% sem perder acurácia (85.5%).
- **Recomendação.** Usar a probabilidade de óbito com corte 0.30 para planejar reforço de conteúdo de segurança por estado, e tratar o modelo como apoio ao planejamento, não como alerta em tempo real (seção 8).

2. Contexto, dados e método

2.1 A base e por que ela foi escolhida

A base vem do **Atlas Digital de Desastres no Brasil** (Secretaria Nacional de Proteção e Defesa Civil, MIDR), que organiza os registros do Sistema Integrado de Informações sobre Desastres (S2iD). Cada linha original é um registro oficial de desastre em um município, com tipologia, data, danos humanos e prejuízos em reais. Usamos a versão consolidada v1.1 (06/08/2026), lida dos arquivos derivados publicados no repositório público Leoneldfernandes/desastres-no-brasil. São dados reais, públicos, nacionais e ligados diretamente ao problema do projeto; nenhum dado foi gerado artificialmente.

2.2 Como a base de análise foi montada

O script *preparar_base.py* agrega os registros de 2013 a 2025 por **estado (UF) e ano**, o que dá 351 linhas (27 UFs × 13 anos). Chamamos de **enchente** a soma de Alagamentos, Enxurradas e Inundações. Para cada estado-ano a base traz a contagem de registros por tipologia (enchentes, chuvas intensas, movimento de massa, vendavais e ciclones, estiagem e seca) e, só para enchentes, mortos, feridos, desabrigados, desalojados, pessoas afetadas e prejuízo. Usamos o recorte recente e contínuo de 13 anos completos; os anos anteriores têm um padrão de registro muito diferente (de 75 registros em 1991 a 1 583 em 2009). Estado-ano sem registro entra com zero.

Qualidade. 351 linhas, 0 valores faltantes, e a soma de alagamentos, enxurradas e inundações bate com o total de enchentes em todas as linhas (diferença máxima 0). 49 estados-ano (14%) não têm nenhuma enchente registrada, e 94 (27%) têm ao menos uma morte por enchente.

2.3 Escala logarítmica

As contagens e os danos têm cauda longa à direita: poucos estados-ano concentram valores enormes. Por isso todas as análises usam **$L(x) = \log10(1 + x)$**. O "+1" preserva os zeros. A tabela mostra o efeito sobre a assimetria; quanto mais perto de zero, mais simétrica a distribuição.

Variável (por estado-ano)	Média	Mediana	Máximo	Assimetria original	Assimetria em log10(1+x)
Registros de enchente	19.2	7.0	211	3.23	0.18
Chuvas intensas	26.1	3.0	527	4.74	0.62
Movimento de massa	3.4	1.0	44	3.15	0.94
Vendavais e ciclones	8.4	1.0	294	7.03	1.02
Estiagem e seca	50.3	10.0	425	1.77	0.11
Desabrigados (enchentes)	1514.0	43.0	70 423	8.82	0.20
Desalojados (enchentes)	6003.2	305.0	112 288	4.07	-0.18

Média, mediana e máximo na unidade original (número de registros ou de pessoas).

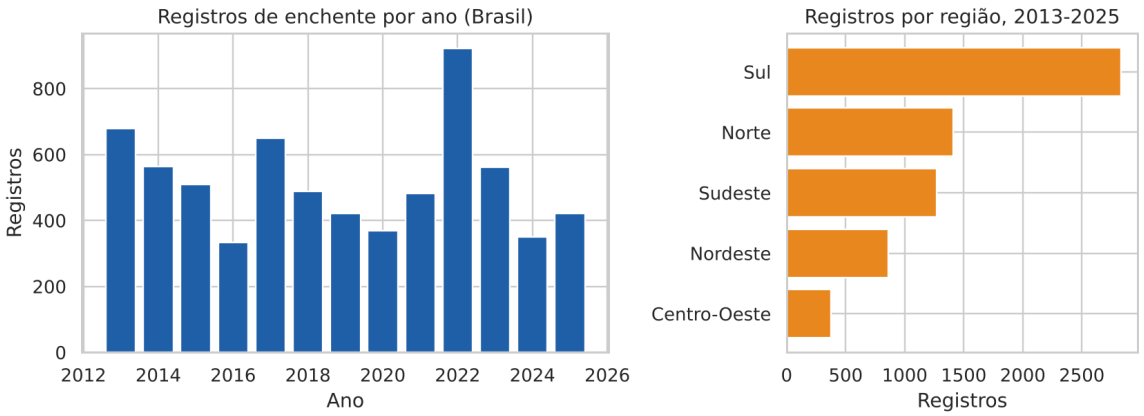


Figura 1. Registros de enchente por ano e por região. 2022 foi o ano com mais registros; o Sul lidera com folga.

3. Probabilidades com a Distribuição Normal

Variável. E = log10(1 + registros de enchente) nos **302 estados-ano com pelo menos uma enchente**. Excluímos os 49 estados-ano sem registro porque eles formam uma barra isolada em zero que não pertence a uma curva Normal. Tratamos as 302 observações como a população: média $\mu = 1.0554$, desvio padrão $\sigma = 0.5110$ e mediana = 1.0000. Em unidades originais, isso equivale a uma média geométrica de 10.4 registros e mediana de 9 registros por estado-ano.

Evento	Cálculo	Probabilidade	Classificação
a) X < média	P(Z < 0)	0.5000	equiprovável (chance semelhante à do evento contrário)
b) X > mediana	P(Z > -0.108)	0.5432	equiprovável (chance semelhante à do evento contrário)

Escala de classificação usada: abaixo de 0.10, muito improvável; de 0.10 a 0.40, improvável; de 0.40 a 0.60, equiprovável; de 0.60 a 0.90, provável; acima de 0.90, muito provável.

Interpretação. Em (a) a probabilidade é exatamente 0.50, porque a Normal é simétrica em torno da média. Em (b) a mediana fica ligeiramente abaixo da média (z = -0.108), por isso a chance de superá-la é um pouco maior que a metade (0.5432). Na prática, um estado-ano com enchente tem tanta chance de ficar acima quanto abaixo do nível típico, que é o esperado de uma variável centrada.

Checagem da hipótese. O teste de Shapiro-Wilk rejeita a normalidade estrita ($W = 0.964$, $p < 0.001$), e a assimetria é 0.35, uma cauda direita leve. Como o enunciado pede que se assuma a Normal, seguimos com ela; os eventos pedidos ficam perto do centro, onde a aproximação erra menos.

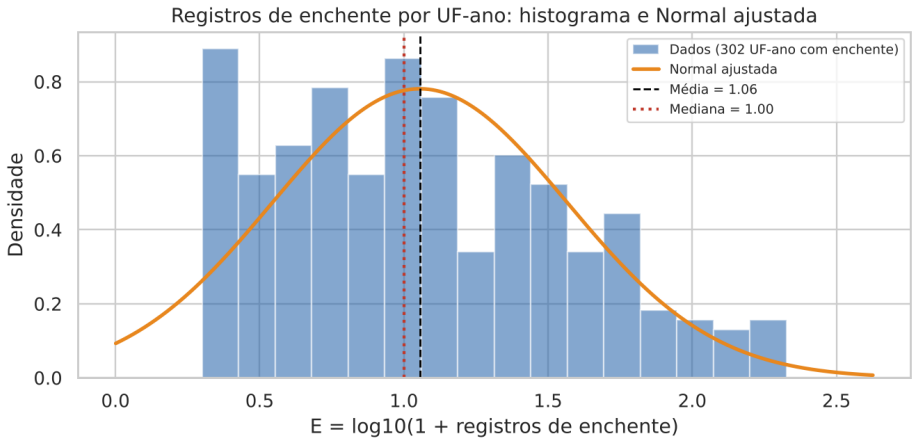


Figura 2. Histograma de E e a curva Normal ajustada; média e mediana praticamente coincidem.

4. Testes de hipótese para a média (teste Z)

Para cada item sorteamos, sem reposição e com semente fixa (2026), uma amostra de estados-ano com enchente. A média de referência é μ0 = 1.0554 e o desvio padrão de referência é o populacional, σ = 0.5110. Estatística: $Z = (\bar{x} - \mu_0) / (\sigma / \sqrt{n})$. H0: μ = μ0.

H1	n	α	$\bar{x}$	Erro padrão	Z calc.	Z crít.	p-valor	Decisão
a) mu < 1.0554	20	6%	1.0598	0.1143	0.039	-1.555	0.5154	Não rejeita H0
b) mu > 1.0554	25	9%	0.9355	0.1022	-1.173	1.341	0.8796	Não rejeita H0

Item (a). A média amostral (1.0598) ficou acima de μ0, então o teste unilateral à esquerda não tem indício contra H0: Z = 0.039 está longe da região de rejeição (Z < -1.555) e o p-valor é 0.5154, maior que α = 6%. **Não rejeitamos H0.**

Item (b). A média amostral (0.9355) ficou abaixo de μ0, e o teste à direita também não encontra evidência: Z = -1.173 contra o crítico 1.341, com p = 0.8796 e α = 9%. **Não rejeitamos H0.**

Leitura. As amostras vêm do mesmo conjunto que define μ0; portanto H0 é verdadeira por construção, e não rejeitá-la é o resultado correto. Se um teste rejeitasse, seria um falso positivo, com chance igual a α. O exercício serve para mostrar o procedimento: com 20 ou 25 estados-ano, só diferenças grandes em relação à média nacional seriam detectadas.

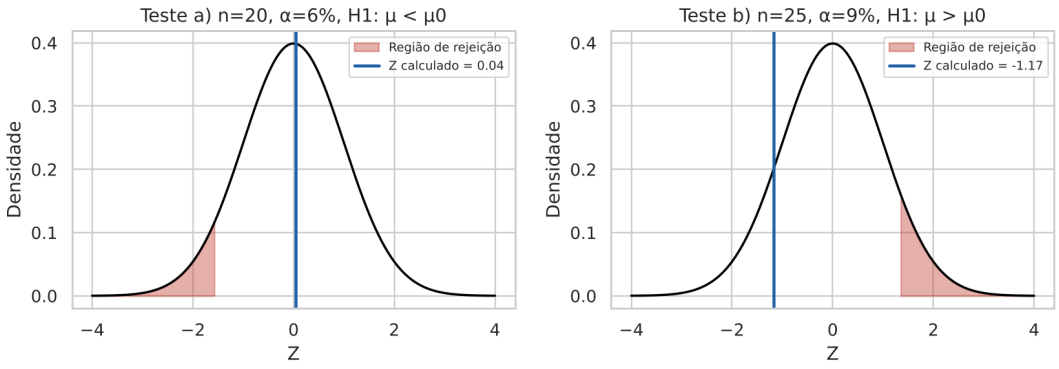


Figura 3. Regiões de rejeição e Z calculado em cada teste; nenhum cai na região de rejeição.

5. Análise bivariada: chuvas intensas e enchentes

Pergunta. Os estados e anos com mais registros de chuvas intensas (C) são os que têm mais registros de enchente (E)? Usamos os 351 estados-ano, na escala log10(1+x).

5.1 Dispersão e interpretação (a)

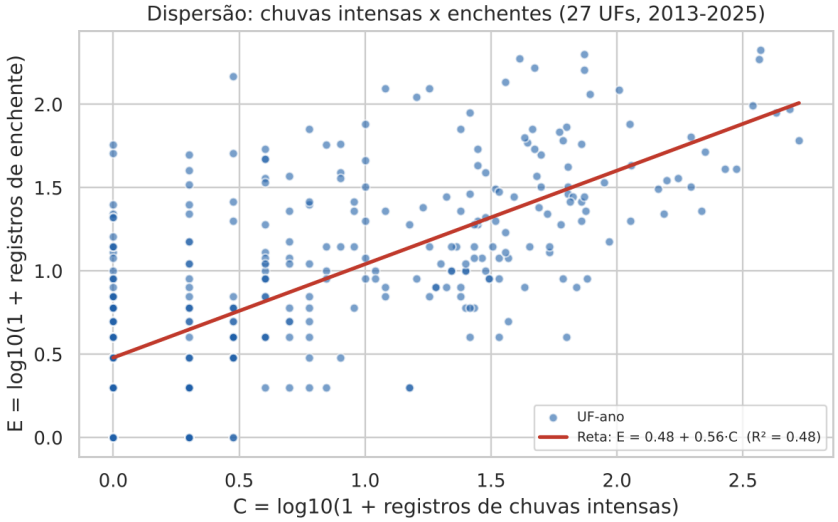


Figura 4. Dispersão entre C e E com a reta de regressão simples.

A nuvem sobe da esquerda para a direita: mais registros de chuvas intensas acompanham mais registros de enchente. Os pontos alinhados em colunas à esquerda são estados-ano com 0, 1, 2 ou poucos registros de chuvas intensas (valores inteiros), e entre eles já há enchentes de tamanhos variados, o que mostra que a chuva registrada não explica tudo.

5.2 Covariância e correlação (b) e gráfico de correlação (c)

Medida	Valor	Interpretação
Covariância (C, E)	0.3047	Positiva: as duas variáveis sobem juntas (a unidade é log² e não se interpreta em magnitude).
Correlação de Pearson r	0.6899	Correlação positiva moderada a forte; p < 0.001.

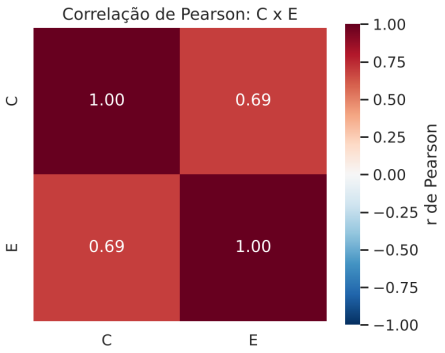


Figura 5. Gráfico de correlação de Pearson entre C e E.

5.3 Reta e equação (d)

$$\mathbf{E = 0.4789 + 0.5615 \cdot C}$$

A inclinação é 0.562 (IC 95%: 0.499 a 0.624). Como as duas variáveis estão em log10, isso é uma elasticidade aproximada: dobrar os registros de chuvas intensas multiplica os de enchente por cerca de $2^{0.562} = 1.48$.

5.4 Adequação do modelo (e)

R^2	R^2 ajustado	Teste F	p-valor de F	Erro padrão residual
0.4760	0.4745	F(1, 349) = 317.00	< 0.001	0.435

O modelo é **estatisticamente significativo** (F com p < 0.001: rejeita-se que a inclinação seja zero). O R^2 mostra que **47.6%** da variação em E é explicada por C; os outros 52.4% dependem de fatores que a base não traz, como relevo, drenagem urbana, população exposta e a chuva medida de fato.

5.5 Previsão (f)

Para um estado-ano com **20 registros de chuvas intensas**, o modelo prevê E = 1.221, ou seja, cerca de **15.6 registros de enchente**. O intervalo de previsão de 95% é largo, de 1.3 a 118.7 registros: serve como ordem de grandeza, não como número exato.

6. Análise multivariada: regressão linear múltipla

Modelo. E = registros de enchente explicados por C (chuvas intensas), M (movimento de massa), V (vendavais e ciclones) e S (estiagem e seca), todos em log10(1+x). A estiagem entra como contraponto: anos secos não deveriam trazer mais enchentes.

6.1 Dispersão (a)

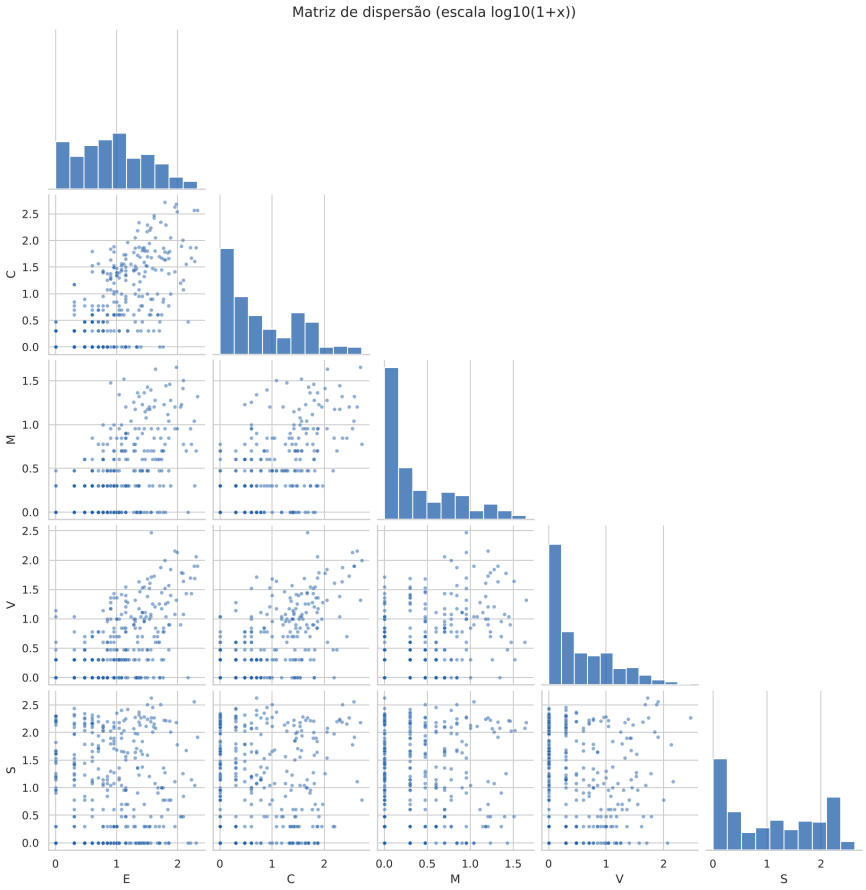


Figura 6. Matriz de dispersão entre E, C, M, V e S.

E cresce com C, M e V, e fica sem padrão visível com S. Os três primeiros também se relacionam entre si, o que faz sentido: o mesmo temporal costuma gerar chuva intensa, deslizamento e vendaval.

6.2 Matrizes de covariância e correlação (b) e gráfico de correlação (c)

Matriz de covariância

	E	C	M	V	S
E	0.359	0.305	0.164	0.217	-0.006
C	0.305	0.543	0.214	0.289	0.058
M	0.164	0.214	0.187	0.130	0.068
V	0.217	0.289	0.130	0.318	0.009
S	-0.006	0.058	0.068	0.009	0.754

Matriz de correlação de Pearson

	E	C	M	V	S
E	1.000	0.690	0.631	0.642	-0.011
C	0.690	1.000	0.670	0.696	0.091
M	0.631	0.670	1.000	0.531	0.179
V	0.642	0.696	0.531	1.000	0.017
S	-0.011	0.091	0.179	0.017	1.000

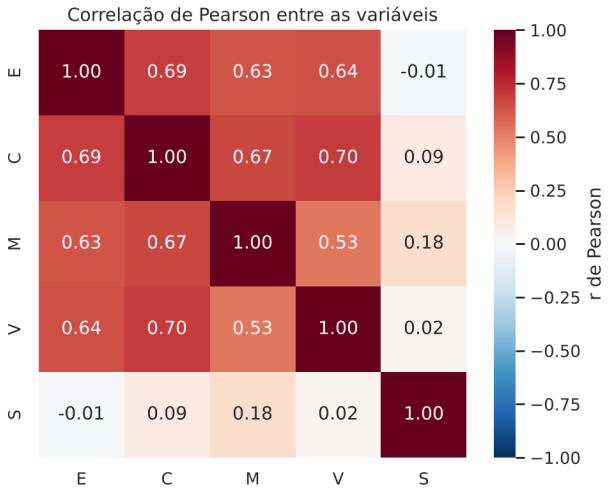


Figura 7. Gráfico de correlação de Pearson entre as cinco variáveis.

Interpretação. E tem correlação positiva com C (0.69), V (0.64) e M (0.63) e praticamente nenhuma com S (-0.01). As correlações entre C, M e V ficam entre 0.53 e 0.70: são parecidas entre si, mas não a ponto de impedir o modelo conjunto (ver VIF abaixo).

6.3 Equação (d)

$$E = 0.4887 + 0.2564 \cdot C + 0.4089 \cdot M + 0.2841 \cdot V - 0.0671 \cdot S$$

Termo	Coeficiente	IC 95%	p-valor	Fator por dobro	VIF
Constante	0.4887	0.413 a 0.565	< 0.001	-	-
C (chuvas intensas)	0.2564	0.167 a 0.346	< 0.001	1.19	2.56
M (movimento de massa)	0.4089	0.278 a 0.540	< 0.001	1.33	1.90
V (vendavais e ciclones)	0.2841	0.181 a 0.387	< 0.001	1.22	1.98
S (estiagem e seca)	-0.0671	-0.116 a -0.019	0.007	0.95	1.04

Leitura dos coeficientes. Mantidas as demais variáveis fixas, dobrar os registros de movimento de massa está associado a cerca de 1.33 vezes mais registros de enchente; vendavais, 1.22; chuvas intensas, 1.19. A estiagem tem sinal negativo (0.95 por dobro): anos mais secos tendem a ter menos enchentes, como esperado. Todos os coeficientes são significativos a 1%.

6.4 Adequação do modelo (e)

R^2	R^2 ajustado	Teste F	p-valor de F	Erro padrão residual	VIF máximo
0.5761	0.5712	F(4, 346) = 117.56	< 0.001	0.393	2.56

O modelo é significativo (F com p < 0.001) e explica **57.6%** da variação de E (R^2 ajustado 0.571), contra 47.6% do modelo com só C: M, V e S acrescentam informação. Os VIFs ficam abaixo de 3, sem multicolinearidade preocupante. O teste de Shapiro-Wilk indica resíduos não Normais (p < 0.001), então os p-valores e intervalos devem ser lidos como aproximados. A Figura 8 mostra os resíduos.

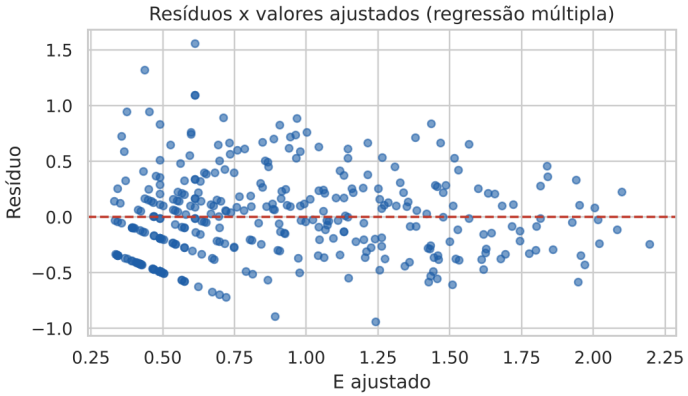


Figura 8. Resíduos contra valores ajustados. As faixas diagonais vêm dos valores inteiros das contagens (inclusive zeros).

6.5 Previsão com mais de uma variável (f)

Cenário: 20 registros de chuvas intensas, 3 de movimento de massa, 5 de vendavais e 10 de estiagem em um estado-ano. O modelo prevê E = 1.225, isto é, cerca de **15.8 registros de enchente** (intervalo de previsão de 95%: 1.8 a 98.8).

7. Regressão logística binária: risco de óbito

Pergunta. Dado o porte das enchentes de um estado em um ano, qual a chance de ter havido **pelo menos uma morte**? Variável resposta: OBITO = 1 se mortes por enchente > 0 (94 dos 351 estados-ano, 26.8%). Explicativas: E (registros de enchente), D (desabrigados) e Dl (desalojados), em log10(1+x).

7.1 Equação (a)

$$\ln(\, p / (1 - p)\,) = -6.3322 + 1.7107 \cdot E + 0.4563 \cdot D + 0.8115 \cdot Dl$$

em que p = P(OBITO = 1). Isolando p: $p = 1 / (1 + e^{-z})$, com z igual ao lado direito da equação.

Termo	Coeficiente	p-valor	Razão de chances por dobro	VIF
Constante	-6.3322	< 0.001	-	-
E (registros de enchente)	1.7107	< 0.001	1.67	2.8
D (desabrigados)	0.4563	0.097	1.15	4.3
Dl (desalojados)	0.8115	0.011	1.28	5.0

Leitura. Todos os sinais são positivos: mais registros, mais desabrigados e mais desalojados aumentam a chance de óbito. A cada **dobro** de registros de enchente, as chances de óbito são multiplicadas por 1.67; por dobro de desalojados, por 1.28. E e Dl são significativos (p < 0.001 e 0.011); D não chega a 5% (p = 0.097), em parte porque desabrigados e desalojados andam juntos (VIF de D e Dl entre 4.3 e 5.0, moderado). O pseudo-R^2 de McFadden é 0.46.

7.2 Matriz de confusão e acurácia (b)

Real \ Previsto (corte 0.50)	Sem óbito	Com óbito
Sem óbito	234 (verdadeiros negativos)	23 (falsos positivos)
Com óbito	31 (falsos negativos)	63 (verdadeiros positivos)

Corte	Acurácia	Sensibilidade	Especificidade	Precisão	Óbitos perdidos (FN)
0.50	84.6%	67.0%	91.1%	73.3%	31
0.30	85.5%	86.2%	85.2%	68.1%	13

Interpretação. Com corte 0.50 a acurácia é **84.6%**: 297 dos 351 estados-ano são classificados corretamente. Em validação cruzada de 5 pastas a acurácia é 84.3% (± 4.6%), muito próxima, o que indica pouco sobreajuste. Como 73.2% dos estados-ano não têm óbito, prever sempre "sem óbito" já acertaria 73.2%; o modelo ganha 11.4 pontos percentuais sobre essa referência. A fraqueza do corte 0.50 é a sensibilidade: ele deixa passar 31 estados-ano com mortes. Com corte 0.30, a sensibilidade sobe para 86.2% e a acurácia não cai (85.5%); o custo são mais falsos alarmes (38 contra 23). Para um serviço de segurança, perder menos óbitos vale mais que evitar alguns alarmes a mais.

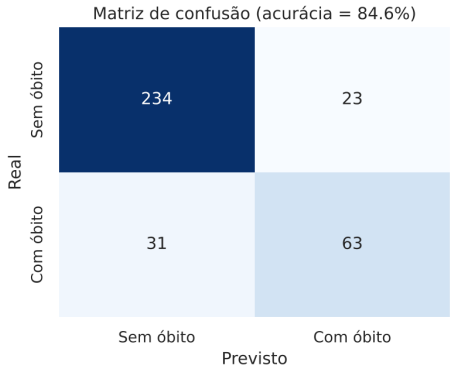


Figura 9. Matriz de confusão do modelo logístico (corte 0.50).

7.3 Classificação com mais de uma variável (c)

Cenário	Entradas	P(óbito)	Classe (corte 0.50)
Porte grande	25 registros, 3000 desabrigados, 12000 desalojados	72.8%	Com óbito
Porte médio	8 registros, 200 desabrigados, 1500 desalojados	25.5%	Sem óbito
Porte pequeno	2 registros, 0 desabrigados, 50 desalojados	1.6%	Sem óbito

No cenário de porte médio a probabilidade fica abaixo de 0.50, mas acima de 0.20; com o corte 0.30 ele continuaria como "sem óbito", e só um corte mais baixo o sinalizaria. Esse é o tipo de decisão que o corte controla.

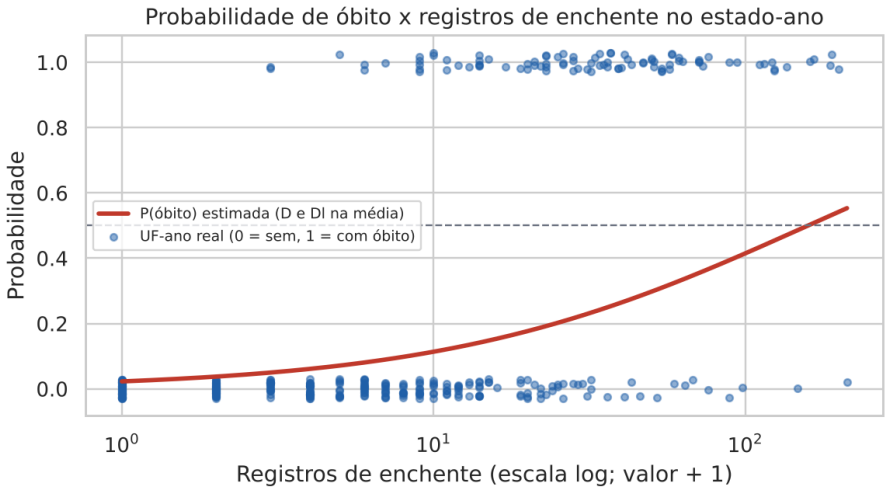


Figura 10. Probabilidade estimada de óbito conforme o número de registros de enchente, com desabrigados e desalojados na média.

8. Insights e recomendações para o Plantão Enchente

Achado	Evidência	O que fazer no assistente
O risco se concentra no Sul	Sul: 2 833 de 6 750 registros (42%); SC e RS à frente de qualquer outro estado.	Priorizar, no conteúdo de orientação e abrigos, os estados de maior volume (SC, RS, PA, MG, AM) antes de ampliar a cobertura.
Chuva registrada acompanha enchente	r = 0.69; dobrar chuvas intensas ↔ ×1.48 enchentes.	Usar o aviso de chuva intensa da Defesa Civil como gatilho para o assistente puxar as orientações de enchente.
Eventos extremos andam juntos	Movimento de massa e vendavais elevam os registros de enchente (R^2 = 0.58).	Quando houver aviso de deslizamento ou vendaval, oferecer também o roteiro de enchente.
Porte da enchente indica risco de morte	Acurácia 84.6%; sensibilidade 86.2% com corte 0.30.	Em estados com alto volume de registros, reforçar mensagens de segurança e de evacuação (corte 0.30).
Muita gente fica sem casa	531 422 desabrigados e 2 107 137 desalojados em 13 anos.	Explicar como achar abrigo, o que levar e como recuperar documentos, que é onde o assistente mais ajuda o cidadão.

Como medir se as recomendações funcionam. O enunciado pede indicadores de acerto das orientações, tempo para achar a informação e facilidade de uso. Os modelos deste relatório entram como apoio ao planejamento; esses três indicadores devem ser medidos nos testes com usuários do protótipo.

9. Limitações

- **Registro não é medição.** "Chuvas intensas" é a quantidade de registros oficiais desse tipo, não milímetros de chuva. Os dados refletem também a capacidade de cada estado de registrar desastres; estados com defesa civil mais ativa registram mais de tudo, e isso infla as correlações.
- **Associação, não causa.** Os modelos descrevem relações entre contagens; não provam que uma variável causa a outra.
- **Escala estado-ano.** O modelo logístico responde sobre um ano inteiro de um estado, não sobre um dia ou um município. Ele serve para planejar conteúdo e cobertura, não como alerta em tempo real; para isso o assistente deve consumir alertas oficiais do Cemaden, do INMET e da Defesa Civil.
- **Valores nominais.** Os prejuízos em reais não foram corrigidos pela inflação e não entram nos modelos; aparecem só no panorama.

- **Normalidade aproximada.** Shapiro-Wilk rejeita a normalidade da variável (seção 3) e dos resíduos (seção 6); usamos a Normal porque o enunciado pede, e lemos p-valores e intervalos como aproximados.
- **Fonte derivada.** Lemos os registros de arquivos derivados do Atlas publicados em repositório público; para uso oficial, convém conferir contra o arquivo original do Atlas Digital (atlasdigital.mdr.gov.br).

10. Reprodutibilidade e fontes

Arquivos entregues: **enchentes_brasil_uf_ano_2013_2025.csv** (base), **analise_enchentes.py** (itens 02 a 06; gera as figuras e o resultados.json) e este relatório em PDF; **preparar_base.py** documenta como a base foi montada. Para reproduzir: *pip install numpy pandas scipy statsmodels scikit-learn matplotlib seaborn* e *python analise_enchentes.py* na pasta do CSV. Semente aleatória: 2026.

Fontes. Atlas Digital de Desastres no Brasil (Sedec/MIDR), atlasdigital.mdr.gov.br, versão consolidada v1.1 de 06/08/2026, originado no S2iD; arquivos derivados lidos de github.com/Leoneldfernandes/desastres-no-brasil; bibliotecas pandas, NumPy, SciPy, statsmodels, scikit-learn, matplotlib e seaborn.